

BuyGuardian: Dokumentacija Koda i Arhitekture Sistema

Ova dokumentacija pruža pregled softverske arhitekture, mikroservisnog dizajna i ključnih modula BuyGuardia agenta. Sistem je dizajniran tako da omogući apstrakciju i automatsko prilagođavanje ekstrakcije podataka svim kategorijama OLX.ba. Iako je trenutni demo sistema prikazan na zahtjevnim oglasima iz kategorije 'Mobiteli', arhitektura softvera omogućava dodavanje novih kategorija kroz jednostavno mapiranje generalnih prompt šablona i specifičnih za kategorije .

1. Arhitektura Sistema na Visokom Nivou

BuyGuardian koristi modernu **Event-Driven Mikroservisnu Arhitekturu**, podijeljenu u četiri glavna stuba, orkestriranu putem Docker Compose okruženja za laku prenosivost i skalabilnost:

1. **Scraper Engine (Python):** Sistem za prikupljanje podataka, korištenjem Playwright-a svoje rezultate efikasno sprema u Redis queue.
2. **LLM Enricher:** Dinamičko obogaćivanje podataka putem LLM-a orkestriran od strane Ollame.
3. **Backend API (.NET 8 / C#):** Centralni servis koji koristi CQRS pattern (MediatR), asinhrono komunicira sa bazom podataka (PostgreSQL) i služi kao API Gateway prema klijentima.
4. **ML Service (Python / FastAPI):** Mikroservis posvećen prediktivnom modeliranju i evaluaciji pravila. Hostuje istrenirane modele i vrši predikcije.
5. **Korisnički Interfejs (Angular 21):** Browser ekstenzija koja se injektuje u DOM ciljane web stranice, komunicira sa Backend API-jem i pruža korisniku vizuelni uvid u metrike.

Komunikacija između servisa odvija se sinhrono putem HTTP REST poziva i asinhrono putem Message Brokera (RabbitMQ i Redis).

2. Dizajnerske Odluke

Izbor tehnologija u arhitekturi je prilagođen specifičnim zahtjevima koje smo imali:

- **Python za Scraping i ML:** Odabran zbog dobro utemeljenog ekosistema (Playwright, Scikit-learn, CatBoost, Ollama klijenti itd). Python omogućava brzu obradu i rad nad Data Science zadacima i jednostavno upravljanje LLM promptovima.
- **.NET 8 (C#) za Orkestraciju:** Odabran kao Backend API zbog visokih performansi, robusne tipizacije i pouzdanosti pri asinhronom radu sa brokerima RabbitMQ i SignalR WebSockets konekcijama te zbog lakšeg rada sa bazom putem Entity Frameworka.
- **PostgreSQL + pgvector:** Ključna prednost i odluka je upotreba **jsonb** kolona za spremanje varijabilnih atributa oglasa bez fiksne šeme. Također, sistem je dizajniran imajući u vidu snagu **pgvector** ekstenzije, koja omogućava vektORIZIRANU (semantičku) pretragu nad oglasima (npr. Proizvode sličnih karakteristika) putem instance Embedder-a.
- **Redis za Cache i Queuing:** Korišten kao in-memory repozitorij za brzi prenos HTML-a između scraperskih workera, te kao glavni cache sloj u Backend API-ju za drastično smanjenje latency-a pri višestrukim korisničkim zahtjevima nad istim oglasom.

3. Životni Ciklus Podataka (Application Flow)

Da bismo u potpunosti razumjeli arhitekturu, pratimo putanju jednog oglasa kroz BuyGuardian sistem:

1. **Scraping:** Raw HTML oglasi i njihovi metapodaci kupe se Playwright orkestratorom koji upotrebljava *stealth* mehanizme za smanjenje vjerovatnoće blokiranja od strane WAF-ova. Sirovi tekst smješta se u In-Memory Redis red čekanja (olx:raw_listings).
2. **LLM Obogaćivanje (Ollama NLP Agent):** Python Worker čita breadcrumbs (npr. "Vozila > Automobili") sistema učitava specifičan prompt i JSON Output shemu. Ovi podaci se šalju lokalnoj **Ollama** instanci koja ima pokrenut **Qwen 2.5 7B** model. Ollama vrši semantičku analizu i normalizaciju teksta, izdvaja specifikacije i stvara tekstualno objašnjenje potencijalnih rizika ("Context Reasoning").
3. **Red Poruka (RabbitMQ):** Obogaćeni JSON se objavljuje u RabbitMQ *exchange* pod nazivom listing_scrape. Ovaj asinhroni korak osigurava da Backend API preuzima poruke tempom koji može obraditi.
4. **Backend Procesiranje (.NET 8):** Servis u pozadini (ListingConsumer) prima JSON podatke, provjerava duplikate, popunjava bazu i izračunava osnovni *Seller Trust*. Cijeli proces je asinhron. Nakon upisa u bazu, backend asinhrono obavještava ML Service i istovremeno, putem **SignalR** WebSockets konekcije, obavještava klijentsku ekstenziju.
5. **Machine Learning Fuzija (Score Fusion):** FastAPI ML Service prvo pokreće **Isolation Forest**. Zatim se taj Anomaly Score, uz karakteristike prodavača i NLP ocjenu opisa, šalje kao ulaz u **CatBoost** regressor koji generiše finalni TrustScore za taj oglas. Rezultati se asinhrono pohranjuju u PostgreSQL bazu, a **SignalR** ponovno šalje obavijest frontendu.
6. **Frontend Prezentacija i Keširanje (Redis Cache):** Kada Angular aplikacija pozove Backend API (AnalyzeListingHandler), API prvo provjerava **Redis Cache**. Ukoliko je oglas keširan, Backend vraća JSON odgovor u nekoliko milisekundi. Ekstenzija iscertava vizuelne komponente i dinamičke savjete na ekranu korisnika.

4. Detaljan Pregled Komponenti (Kodna Struktura)

4.1. Scraper Engine, Ollama & LLM Enrichment (Python)

Fokus ovog modula je na ekstrakciji i semantičkoj analizi oglasa.

- **scraper_engine/scraper/orchestrator.py & Playwright:** Orkestrator služi se playwright-stealth modulom za emulaciju ponašanja stvarnog korisnika, smanjujući šanse za bot detekciju tokom prikupljanja podataka.
- **scraper_engine/scraper/enrich_queue.py:** Worker implementira **Dynamic Template Routing**. Analizom kategorije oglasa, worker bira najadekvatniji šablon i komunicira sa **Ollama** instancom. LLM ekstrahuje attribute i naziv za grupisanje proizvoda (canonical_name), omogućavajući poređenje i grupiranje proizvoda.
- **Obogaćeni Payload:** Worker sprema attribute, generisana objašnjenja i rezultate analize u jedan JSON entitet i objavljuje ga na RabbitMQ.

4.2. Backend API (.NET 8)

Srce sistema dizajnirano po Domain-Driven Design-u i Clean Architecture principima, optimizovano za real-time komunikaciju.

- **BuyGuardian.Api/Services/ListingConsumer.cs:** Implementira BackgroundService. Zadužen za deserijalizaciju JSON payloada, lingvističku normalizaciju, kalkulaciju osnovnih težina povjerenja prodavača i slanje real-time rezultata klijentima putem **SignalR (AnalysisHub)**.
- **BuyGuardian.Api/Features/AnalyzeListingHandler.cs (CQRS & Redis Caching):** Procesira REST upite sa Angular ekstenzije. Njegova ključna prednost je implementacija **RedisCacheService**. Svaki izračunati Trust Score se serijalizuje u Redis sa TTL mehanizmom, drastično ubrzavajući sistem pri višestrukim pregledima.
- **Data Layer (Entity Framework Core & PostgreSQL & pgvector):** Koristi se PostgreSQL-ov jsonb tip kolone za pohranjivanje RawMetadata, omogućavajući čuvanje varijabilnih atributa bez fiksne C# šeme. Arhitektura baze je prilagođena za integraciju **pgvector** ekstenzije, čime je omogućen efikasan rad sa ML embedding vektorima i semantička pretraga nad milionima artikala.

4.3. Machine Learning Service (FastAPI / Scikit-learn / CatBoost)

Izolovan mikroservis dizajniran za scoring.

- **ml_service_listing/domain/scoring.py i rules.py:** Skup deterministički definisanih pravila koja evaluiraju kritične attribute (drastično neslaganje specifikacija sa naslovom, potpuno prazan opis, nedostajući atributi) za formaciju inicijalnog skupa podataka koji se iskoristi za treniranje i evaluaciju CatBoost modela. Nakon formacije skupa i treniranja modela, posao dodjeljivanja ocjene povjerljivosti za nove oglase se prepušta CatBoost modelu.
- **ml_service/models/isolation_forest.py:** model operira u osmo-dimenzionalnom prostoru koji obuhvata cjelokupnu sliku oglasa unutar klastera istog proizvoda. Osam dimenzija su: **Relativno cjenovno odstupanje** koliko cijena oglasa odstupa od medijana svih oglasa za isti proizvod na platformi, **Odnos stanja i cijene**, omjer prijavljenog fizičkog stanja artikla prema normaliziranoj cijeni, koji otkriva slučajeve gdje prodavač traži visoku cijenu za artikal u lošem stanju, **Težina garancije** binarni signal koji razlikuje oglase sa i bez ponuđene garancije, **Pouzdanost prodavača** signal izveden iz logaritamske kombinacije broja uspješnih dostava i starosti, **Volatilnost cijene** standardna devijacija historije cijena oglasa normalizirana medijanom grupe, koja detektuje manipulativne obrasce poput naglog spuštanja cijene prije prodaje, **Starost oglasa** broj dana od prvog scrapinga, budući da novi oglasi s ekstremnim cijenama nose veći rizik, **Omjer negativnih recenzija** odnos negativnih prema pozitivnim recenzijama prodavača, i **Spam score opisa** heuristička mjera kvaliteta teksta izvedena iz omjera velikih slova i broja uskliknika u opisu.
- **ml_service_listing/models/catboost_predictor.py:** Nakon što formiramo inicijalni skup podataka (formacija se obavlja ručno samo jednom kada se na novoj bazi akumulira bar 1000 oglasa) CatBoost model se koristi za predikciju ocjene povjeljivosti za sve nove oglase, feature-i koji ulaze u model su infomacije o oglasu (kao condition, overpay_ratio, warranty_months, writing_quality, manufacturer_mismatch i dr.), ocjena je u rangu [0.00,1.00], ali se korisniku prikaže kao [0.0, 10.0].

4.4. Frontend UI (Angular 21)

Korisnički sloj koji djeluje kao ekstenzija.

- **buyguardian-ui/src/content.ts (DOM Injektor):** Prati promjene URL-a preko Mutation Observers i injektuje Shadow DOM komponentu koja izolira CSS stilove widgeta.
- **buyguardian-ui/src/app/app.ts:** Angular modul komunicira sa API-jem.