

BuyGuardian

Opis i primjena

BuyGuardian je inteligentni agent koji je zamišljen kao dopuna OLX.ba korisničkog iskustva, djeluje kao browser ekstenzija koja korisnicima pruža uvid u kvalitetu i ključne kontekstualne informacije o oglasu u cilju da ih zaštite od loših kupovina i prevara, dok im istovremeno pruža sigurnije alternative.

Agent autonomno prikuplja podatke o oglasu, semantički analizira tekstualni sadržaj, upoređuje cijenu sa tržišnim prosjekom na platformi i evaluira historiju prodavača, te na osnovu toga formira kompozitnu ocjenu povjerenja koju prezentuje korisniku kroz vizualni badge i detaljan breakdown. Cilj je zaštititi korisnika, uštediti mu vrijeme i pomoći mu pri pronalaženju najbolje ponude.

Arhitektura agenta

Agent je realiziran kao **višeslojni hibridni sistem** koji kombinuje tri komplementarna pristupa donošenju odluka. NLP Agent (LLM Qwen 2.5 7B) orkestriran putem Ollama platforme, vrši semantičku analizu nestrukturiranog teksta oglasa. LLM extract-a tehničke specifikacije, detektuje rizične obrasce u opisu (npr. skrivene mane, nedostajuće informacije) i generiše kontekstualno obrazloženje (Context Reasoning)¹. ML Agent (Isolation Forest² + CatBoost³) čine izolirani mikroservisi koji vrše dvostepenu predikciju. Prvo, Isolation Forest algoritam detektuje cjenovne anomalije unutar klastera istih proizvoda. Zatim, CatBoost regressor vrši predikciju pomoću svih prikupljenih feature-a (kvalitet opisa iz LLM-a, anomaly score, stanje proizvoda) i generiše finalnu ocjenu povjerljivosti za oglas.

Način učenja

BuyGuardian koristi **inkrementalno online učenje** kao primarni mehanizam adaptacije. Agent uči na dva načina:

- **Samooznačavanje (Self-Labeling):** Svaki novi oglas koji prođe kroz pipeline automatski se koristi kao podatak za treniranje. Kompozitni score koji sistem dodijeli oglasu služi kao oznaka (label) za taj primjerak. Ako sistem nije dovoljno siguran u sebe, vraća na human review tzv. Human in the Loop pristup. Ovo omogućava sistemu da kontinuirano raste i da eventualno na osnovu human feedback-a samostalno radi anotaciju podataka..
- **Inkrementalni re-trening (Incremental Retraining):** Nakon svake predikcije, novi podatak se asinhrono dodaje u training dataset, a CatBoost model se ažurira putem mehanizma koji nastavlja treniranje od postojećeg stanja modela sa novim iteracijama, umjesto da trenira ispočetka. Dodatno, sistem podržava i potpuni re-trening (full retrain) na cijelom akumuliranom datasetu kada administrator to zahtijeva⁴.
- **Nenadgledano učenje tržišta (Isolation Forest Periodic Retraining):** Za razliku od CatBoost-a koji uči iz označenih primjera (nadgledano učenje), Isolation Forest koristi nenadgledano učenje ne treba mu labela, već uči šta je "normalno" za svaki klaster proizvoda analizirajući distribuciju svih 8 dimenzija (cijena, stanje, garancija, pouzdanost prodavača, volatilnost cijene, starost oglasa, negativne recenzije, spam score). Periodični scheduler automatski pokreće re-trening svih Isolation Forest modela svakih 6 sati. Za svaki proizvod sa dovoljno oglasa (≥ 5), sistem ponovo izgrađuje matricu obilježja, prilagođava RobustScaler i trenira novi model koji se kešira u Redis. Time se modeli konstantno prilagođavaju promjenama tržišnih cijena, novim prodavačima i sezonskim promjenama.

¹ Yang, A., Yang, B., Hui, B., et al. (2024). Qwen2.5 Technical Report. <https://arxiv.org/abs/2412.15115>

² Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest.. <https://doi.org/10.1109/ICDM.2008.17>

³ Dorogush, A. V., Ershov, V., & Gulin, A. (2018). CatBoost: gradient boosting with categorical features support. <https://arxiv.org/abs/1810.11363>

⁴ Russell, S. J., & Norvig, P. (2021). Artificial Intelligence: A Modern Approach (4th ed.). Pearson. -Poglavlja 2 (Intelligent Agents) i 19 (Learning from Examples).